¿Qué cuesta la inteligencia artificial?

Desafíos legales y ambientales de la IA contemporánea

Manuel Soto Romero

20 de septiembre de 2026
Colegio de Ciencia y Tecnología UACM

1. Introducción

Una herramienta de inteligencia artificial (IA) puede responder una pregunta en pocos segundos. Esa rapidez hace que el proceso parezca simple. Sin embargo, detrás de la respuesta hay datos, modelos, servidores, electricidad, agua y muchas decisiones humanas. También hay personas y organizaciones que eligen para qué se usará el sistema, qué información recibirá y qué ocurrirá si se equivoca. La IA no es sólo un programa: forma parte de una red técnica, social e institucional que debe ser gobernada durante todo su ciclo de vida (desde el diseño hasta su retiro) [1].

Esta red abre posibilidades, pero también crea riesgos. Un sistema puede ayudar a ordenar información, apoyar una investigación o agilizar una tarea. El problema cambia cuando participa en decisiones que afectan un empleo, la privacidad o el trato que recibe una persona. En México, por ejemplo, se han señalado riesgos para la privacidad y la no discriminación, así como la falta de reglas específicas para ciertos usos de la IA [2]. Esto no significa que toda aplicación sea igual de peligrosa. El riesgo depende de la tecnología, de su finalidad y del contexto. Por esa razón, regular bien no consiste en imponer la misma carga a todos los sistemas, sino en pedir controles acordes con el daño que podrían causar [3].

Hay otro costo menos visible. Los sistemas de IA funcionan en centros de datos (grandes instalaciones que reúnen computadoras especializadas) que consumen energía y agua. Su huella ambiental cambia según la eficiencia de los equipos, el sistema de enfriamiento, la fuente de electricidad y el lugar donde se encuentran los servidores [4]. Incluso dos centros de datos que realizan tareas parecidas pueden usar cantidades muy distintas de agua [5]. Por eso, frases como «la IA consume cierta cantidad» suelen ser incompletas si no explican qué sistema se midió, dónde operaba y qué parte de su ciclo de vida se tomó en cuenta.

Este ensayo sostiene que no basta con preguntar qué puede hacer una IA. También hay que preguntar en qué condiciones se desarrolla y se usa, quién se beneficia, quién asume los riesgos y cuáles son sus costos jurídicos, sociales y ambientales. Los dos ejes comparten un problema: muchos de esos costos permanecen ocultos cuando no existen datos, responsables y formas de revisión claramente definidos. Esta postura evita dos extremos. El primero presenta la IA como una solución

automática para cualquier problema. El segundo la trata como una amenaza única y uniforme. En ambos casos se pierde de vista lo más importante: los efectos dependen de decisiones concretas sobre diseño, uso, supervisión e infraestructura.

El análisis se concentra en la gobernanza legal y la huella ambiental. No pretende reunir todos los dilemas éticos de la IA ni calcular una cifra universal sobre su impacto. Su objetivo es distinguir qué puede afirmarse con la evidencia revisada, qué límites conserva esa evidencia y qué preguntas siguen abiertas. Para ello, primero explica algunos rasgos de la IA contemporánea; después examina los problemas legales y ambientales; y, al final, muestra los puntos en los que ambos se conectan.

2. La IA hoy en día

Hablar de «la IA» puede dar la impresión de que existe una sola tecnología. No es así. El término reúne sistemas muy distintos, con diferentes grados de complejidad y autonomía. Algunos clasifican información; otros hacen predicciones; otros generan texto, imágenes o sonido. Estos últimos forman parte de la llamada IA generativa. Su expansión reciente aumentó la presencia pública de la tecnología. El lanzamiento de ChatGPT a finales de 2022 fue un punto de cambio en la demanda de estos servicios y en la instalación de equipos para operarlos [4].

Una parte de esta expansión se explica por los modelos preentrenados. Son programas que aprenden patrones a partir de grandes conjuntos de datos y después pueden adaptarse a varias tareas. Un mismo modelo de lenguaje, por ejemplo, puede servir como base para resumir, responder preguntas o producir borradores. Esto no significa que tenga una capacidad universal ni que funcione igual en cualquier situación. Cada aplicación agrega sus propios datos, reglas, formas de presentar los resultados y objetivos [6]. También agrega riesgos. No es lo mismo usar un modelo para sugerir una frase que incorporarlo a un proceso de contratación.

El aumento de capacidades ha venido acompañado por modelos, conjuntos de datos y trabajos de cómputo cada vez mayores. Durante años, buena parte de la investigación valoró sobre todo la precisión o el desempeño en pruebas. Ese enfoque dejaba en segundo plano el costo económico, social y ambiental de obtener los resultados [6]. La propuesta conocida como *Green AI* (IA verde) busca corregir ese desequilibrio. Plantea que la eficiencia también debe contar y que los trabajos deberían informar cuánto cómputo necesitaron [7].

Para entender ese costo conviene distinguir dos momentos. El *entrenamiento* es el proceso mediante el cual se ajusta un modelo. Puede exigir muchas pruebas antes de llegar a una versión final. La *inferencia* ocurre después, cuando el modelo recibe una solicitud y produce una respuesta. Una sola inferencia puede usar menos recursos que el entrenamiento, pero un servicio masivo repite ese proceso una gran cantidad de veces. En esos casos, la suma de las consultas puede pesar más que el entrenamiento inicial [7].

Nada de esto ocurre en el aire. Los modelos funcionan en procesadores instalados en servidores (computadoras preparadas para atender tareas y solicitudes). Los servidores se alojan en centros

de datos que necesitan electricidad, conexión de red, sistemas de respaldo y enfriamiento. Por eso, el tamaño de un modelo no basta para conocer su impacto. También importa qué equipo lo ejecuta, cuántas veces se usa, cuánto tiempo permanece activo, cómo se enfría y de dónde viene la energía [4, 5].

Además, la salida del modelo rara vez es la decisión completa. Una persona puede aceptarla, corregirla o ignorarla. Una organización decide cuánto peso darle y si existe una forma de revisarla. El resultado final depende de la relación entre el modelo, la interfaz que presenta sus resultados, quienes lo operan y las reglas de la institución [8]. Esta es la razón por la que conviene hablar de sistemas sociotécnicos: sistemas en los que la tecnología y la organización humana actúan juntas.

Esta mirada prepara los dos problemas centrales del ensayo. El primero es jurídico: ¿qué reglas y responsabilidades se necesitan cuando el riesgo cambia según el uso? El segundo es ambiental: ¿cómo se mide una huella que depende de equipos, lugares y formas de operación muy diferentes?

3. Desafíos legales

Los problemas legales de la IA no aparecen sólo porque la tecnología sea nueva. Surgen cuando principios como privacidad, igualdad, transparencia y responsabilidad deben convertirse en acciones concretas. En el desarrollo y uso de un sistema participan muchas personas: quienes crean el modelo, quienes ofrecen la infraestructura, quienes lo compran, quienes lo operan y quienes reciben sus efectos. Por eso, gobernar una IA implica mirar algo más que el algoritmo (el conjunto de instrucciones y reglas que sigue el sistema). También hay que revisar sus datos, sus pruebas, su forma de uso y las opciones que existen para corregir una decisión [1].

3.1. Regular según el riesgo y el contexto

Una regla basada en riesgos parte de una idea sencilla: no todos los usos de la IA necesitan el mismo nivel de control. Una aplicación recreativa no tiene las mismas consecuencias que un sistema usado para contratar personal o evaluar su desempeño. Las obligaciones deben responder a la finalidad del sistema, al contexto y a la gravedad del daño posible. Incluso un mismo modelo puede tener un riesgo bajo en una tarea y uno alto en otra [3].

La proporcionalidad también importa para las organizaciones. Documentar, evaluar y certificar un sistema puede prevenir daños y aumentar la confianza. Sin embargo, una exigencia general puede ser difícil de cumplir para organizaciones pequeñas o para actores que no tienen acceso al modelo. Ordelin Font advierte que las cargas mal diseñadas pueden crear inseguridad jurídica (dudas sobre lo que exige la ley), favorecer la concentración del mercado o resultar inútiles [3]. Esto no es un argumento para eliminar controles. Es una razón para asignarlos a quienes poseen la información y la capacidad de actuar.

También conviene distinguir regulación y gobernanza. La *regulación* establece obligaciones, prohibiciones, autoridades y consecuencias legales. La *gobernanza* incluye todo eso, pero abarca además políticas internas, estándares, evaluaciones, auditorías y acuerdos entre instituciones. Estas

medidas deben existir antes, durante y después del desarrollo de un sistema [1]. Las reglas nacionales y la cooperación internacional tampoco son opciones excluyentes. Las primeras permiten exigir responsabilidades dentro de un país. La segunda ayuda a atender modelos, empresas e infraestructuras que operan en varios países.

3.2. Distintos caminos para regular la IA

«Regular la IA» puede significar cosas muy diferentes. Una ley puede abarcar muchos sectores y ordenar los sistemas según su riesgo. Otra puede concentrarse en un servicio concreto, como las recomendaciones automatizadas. También es posible aplicar normas ya existentes mediante autoridades especializadas. Cada elección responde a una pregunta distinta: ¿se regula la tecnología, el uso que se le da, el proveedor que la ofrece o el sector donde produce efectos?

La Unión Europea eligió una regulación horizontal: una norma común para diferentes sectores, con obligaciones que cambian según la categoría de riesgo. Este diseño busca crear un piso compartido y concentrar los controles más exigentes en los usos que pueden afectar la seguridad o los derechos. Su ventaja es que evita dejar cada sector sin orientación. Su dificultad consiste en clasificar tecnologías que cambian y que pueden cumplir varias funciones. Además, una clasificación general no elimina los problemas de aplicación, supervisión y coordinación con otras leyes [9, 10].

China siguió un camino escalonado. Antes de sus medidas para servicios de IA generativa, ya había regulado las recomendaciones algorítmicas y la síntesis profunda, que incluye tecnologías usadas para producir contenidos falsos o alterados. Esta secuencia atiende servicios específicos y asigna obligaciones a sus proveedores. En las medidas sobre IA generativa pesan tanto el fomento de la industria como la seguridad, el control de contenidos y la estabilidad social [10, 11]. No es simplemente una versión más estricta del modelo europeo: parte de otras prioridades y distribuye la autoridad de otra manera.

India ofrece un contraste. El estudio comparativo de Zhang y sus colaboradores describe un proceso más incremental, apoyado en orientaciones, consultas, normas existentes y medidas dirigidas a aplicaciones particulares. Los autores relacionan este resultado con una definición del problema centrada en el uso de la IA en distintos sectores y con una participación más diversa en la elaboración de políticas. El mismo estudio advierte que esta apertura produce acuerdos más graduales y menos mandatos generales; no demuestra que una regulación ligera sea siempre mejor ni que permanezca igual cuando madure la industria [11].

Estados Unidos ha distribuido históricamente la intervención entre agencias, sectores y niveles de gobierno, sin un marco federal único comparable con el europeo. Esa flexibilidad permite actuar desde competencias ya existentes, pero puede dejar vacíos y respuestas desiguales. En el Reino Unido, la coordinación entre reguladores especializados representa otra forma de aprovechar instituciones sectoriales, aunque coordinar varias autoridades no garantiza por sí mismo criterios uniformes [10]. Una regulación sectorial conoce mejor el ámbito que vigila; una horizontal puede ofrecer reglas comunes. Ninguna resuelve automáticamente la relación entre un modelo de propósito general y los muchos usos que otras organizaciones construyen con él.

Estas diferencias impiden tratar las experiencias internacionales como una competencia para elegir un ganador. También explican por qué una regla internacional y las normas nacionales pueden convivir. La cooperación ayuda a establecer principios, vocabularios y formas de evaluación para tecnologías que cruzan fronteras. Las instituciones nacionales convierten esos acuerdos en autoridades, procedimientos y remedios adecuados a su marco jurídico. Para México, la lección no consiste en copiar una arquitectura completa, sino en preguntar qué problema se quiere resolver, quién tiene capacidad para intervenir y qué combinación de reglas generales y sectoriales puede aplicarse realmente.

3.3. Privacidad y no discriminación

La privacidad se refiere al modo en que se reúnen, procesan y usan los datos personales. La no discriminación busca evitar que una decisión perjudique de manera injusta a una persona o a un grupo. Ambos problemas suelen aparecer juntos. En un proceso de contratación, por ejemplo, los datos usados para evaluar a una persona pueden revelar información privada y, al mismo tiempo, producir diferencias de trato [2].

Un estudio sobre México identifica vacíos en la regulación específica de la IA y señala posibles riesgos en sistemas usados para contratación y evaluación laboral [2]. Es importante leer este resultado con cuidado. El estudio analiza documentos legales, informes y literatura. No mide cuántos casos de discriminación algorítmica ocurren en el país. Su aporte consiste en mostrar que los derechos generales necesitan mecanismos concretos cuando una decisión se apoya en IA.

Quitar de los datos una característica que la ley protege frente a la discriminación no demuestra que el sistema sea neutral. Otras variables pueden estar relacionadas con ella. Tampoco basta con elegir una sola medida matemática de equidad (una forma de comparar si los grupos reciben un trato justo). Distintas medidas pueden entrar en conflicto, y la intervención de las personas puede cambiar el resultado final [8]. Una evaluación seria debe explicar qué daño busca evitar, qué grupos analiza, qué medida usa y qué sucede después de la recomendación del modelo. También necesita una vía para corregir datos, cuestionar decisiones y reparar daños.

3.4. Transparencia, explicación, seguimiento y auditoría

Estos cuatro conceptos suelen mezclarse, pero responden a preguntas diferentes. La *transparencia* permite saber para qué existe el sistema, qué datos usa, quién participa, cómo funciona, cuáles son sus límites y qué controles tiene. La *explicabilidad* intenta aclarar por qué apareció un resultado determinado. Una explicación puede ser parte de la transparencia, pero no la reemplaza. Saber qué variables influyeron en una recomendación no revela quién decidió usarla ni qué opciones tiene una persona para cuestionarla [8].

La información tampoco sirve igual para todo el mundo. Un equipo técnico puede necesitar detalles sobre versiones y pruebas. Una autoridad puede buscar evidencia de cumplimiento. Una persona afectada necesita entender qué ocurrió y cómo puede responder. Además, describir un

procedimiento no demuestra que haya funcionado. Por eso, la transparencia debe incluir tanto lo que se planeó como los resultados observados en la práctica [8].

La *trazabilidad* es la posibilidad de reconstruir la historia del sistema. Incluye el origen y los cambios de los datos, las versiones del modelo, las pruebas, las personas responsables y los incidentes. La *auditabilidad* es algo distinto: significa que el sistema puede ser evaluado de manera ordenada frente a criterios definidos. Para auditar no basta con acumular documentos. Se necesita acceso, información útil, un objeto claro y una norma o estándar con el cual compararlo [12].

Las auditorías pueden mirar el sistema desde dos ángulos. Una auditoría técnica estudia sus entradas, salidas y errores. Una auditoría institucional revisa los datos, los procesos de desarrollo, la validación, la gestión de calidad y la supervisión. La primera ayuda a ver qué hace el sistema. La segunda ayuda a entender por qué lo hace y si la organización puede corregirlo [12]. Las dos son necesarias, pero ninguna ofrece una garantía permanente.

Toda auditoría tiene límites. Su valor depende de quién decide qué se revisa, qué estándar se usa, cuánta independencia tiene el auditor y qué información puede consultar. También depende de lo que ocurre después, porque un sistema puede cambiar durante su operación. Todavía falta evidencia sobre la eficacia de varios métodos de auditoría, y los proveedores pueden negar datos esenciales cuando no existen facultades legales para obtenerlos [12].

3.5. Quién responde y qué significa supervisar

Responsabilidad y rendición de cuentas no son lo mismo. La responsabilidad atribuye una conducta o un daño a alguien. La *rendición de cuentas* crea una relación: una persona u organización debe explicar y justificar lo que hizo ante una instancia capaz de revisar esa explicación y producir consecuencias. Para que esa relación sea clara, hay que precisar el contexto, la conducta, quién responde, ante quién, con qué reglas, mediante qué procedimiento y con qué efectos [13].

Esta tarea se complica porque un daño puede tener muchos orígenes. Puede comenzar con datos sesgados, una prueba insuficiente, una interfaz confusa o un uso distinto del previsto. Si las funciones están mal repartidas, cada actor puede afirmar que sólo controlaba una pequeña parte. Es el problema de las «muchas manos». También puede ocurrir lo contrario: varias autoridades revisan el sistema con criterios distintos, pero ninguna toma una decisión final. Es el problema de las «muchas miradas» [13]. La salida consiste en asignar deberes según la información, el control y la capacidad real de intervención de cada actor.

La presencia de una persona tampoco garantiza una supervisión efectiva. Si el operador no entiende la recomendación, no tiene tiempo para revisarla o no puede cambiarla, su intervención es sólo aparente. Una persona también puede confiar demasiado en el sistema o introducir errores nuevos. Por eso, hay que evaluar la relación completa entre modelo, interfaz, operador y reglas de trabajo [8].

Una rendición de cuentas sólida combina cuatro funciones: cumplir estándares, registrar y explicar las decisiones, supervisar con evidencia y aplicar consecuencias cuando corresponda [13]. Si sólo hay documentos, puede faltar una revisión real. Si sólo se publica información, puede faltar una

autoridad que actúe. Y si sólo se castiga, se pierde la posibilidad de prevenir. También hacen falta formas accesibles de corregir una decisión y reparar el daño.

3.6. Del principio a la práctica

Los desafíos legales de la IA no se resuelven con una regla única ni con una propiedad técnica. Se necesitan controles acordes con el riesgo, protección de derechos, documentos que permitan seguir el ciclo de vida, evaluaciones técnicas e institucionales y una cadena clara de rendición de cuentas. También hay que aceptar los límites: una explicación no elimina todos los riesgos, una fórmula no resuelve por sí sola la discriminación y una auditoría no garantiza el comportamiento futuro.

Por eso, la tensión entre regulación e innovación está mal planteada cuando se presenta como una elección entre control y progreso. Una regla mal diseñada puede imponer costos sin reducir daños. Pero la ausencia de reglas también tiene costos, que suelen recaer en las personas afectadas. La pregunta útil es más concreta: ¿qué control hace falta, quién puede cumplirlo y cómo sabremos si funciona?

4. Desafíos ambientales

La huella ambiental de la IA no vive dentro del algoritmo. Se forma en una cadena que une programas, procesadores, redes, edificios, electricidad, agua y decisiones humanas. Seguir esa cadena permite evitar dos errores. El primero consiste en imaginar que todo comenzó con la IA generativa. El segundo consiste en atribuir a la IA todo el impacto de una infraestructura que también sostiene búsquedas, video, almacenamiento, servicios empresariales y muchas otras actividades digitales.

4.1. La materialidad de la inteligencia artificial

Una respuesta que aparece en una pantalla parece inmaterial, pero depende de servidores instalados en centros de datos. Allí se reúnen procesadores, almacenamiento y equipos de red. La instalación también necesita distribuir electricidad, mantener sistemas de respaldo y retirar el calor. En modelos de gran escala se utilizan aceleradores, como las unidades de procesamiento gráfico o GPU: chips capaces de ejecutar muchas operaciones en paralelo. Esta capacidad puede acelerar el trabajo, pero no elimina su demanda de energía ni la infraestructura que lo sostiene.

La medición cambia según el límite elegido. Puede contar sólo la electricidad que llega al procesador, añadir el enfriamiento y las pérdidas del edificio, o incluir también la fabricación, el transporte y el final de la vida útil de los equipos. Dos servicios parecidos pueden tener impactos distintos por su hardware, su grado de utilización y el lugar donde operan [4, 5].

El agua muestra con claridad esta materialidad. Se usa directamente en algunos sistemas de enfriamiento e indirectamente al producir electricidad. Además, *consumo* y *extracción* no significan lo mismo. El consumo cuenta el agua que no regresa de inmediato a su fuente; la extracción mide todo el volumen retirado, aunque una parte se devuelva. Esta diferencia importa en lugares donde el agua es escasa o cambia con la estación [5].

4.2. Un problema anterior a la IA generativa

Los centros de datos no nacieron con ChatGPT. Mucho antes del auge de la IA generativa ya sostenían Internet, el almacenamiento remoto y los servicios de computación en la nube. También se estudiaban su electricidad, su enfriamiento y su agua. En 2020, Masanet y sus colaboradores describieron a los centros de datos como la base de un mundo cada vez más digitalizado y advirtieron que proyectar su consumo sólo a partir del crecimiento del tráfico podía producir estimaciones engañosas [14].

La razón es importante: más actividad digital no siempre se traduce en un aumento proporcional de electricidad. Entre 2010 y 2018, según ese estudio, las cargas de trabajo y las instancias de cómputo crecieron más de seis veces, mientras varias mejoras redujeron la energía necesaria por operación. Procesadores más eficientes, menor consumo cuando los servidores están inactivos, mayor densidad de almacenamiento, virtualización y traslado hacia instalaciones de nube e hiperescala ayudaron a contener el crecimiento [14]. Esto no significa que el consumo dejara de importar. Significa que demanda y eficiencia deben analizarse juntas.

El agua tampoco apareció como preocupación después de la IA generativa. Un estudio publicado en 2021 ya distinguía el uso directo para enfriamiento del uso indirecto asociado con la electricidad y señalaba la escasez de datos públicos. Menos de una tercera parte de los operadores considerados medía su consumo de agua [15]. La migración a la nube introdujo además una dificultad: quien compra capacidad de cómputo puede dejar de ver los recursos físicos que hay detrás del servicio.

Esta historia cambia la pregunta. La IA contemporánea no creó desde cero un problema ambiental. Se instaló sobre una infraestructura material que ya crecía y que ya tenía impactos. Lo nuevo debe buscarse en el tipo de equipos, la composición de las cargas y la velocidad con que aumenta la demanda.

4.3. ¿Qué cambia con la IA contemporánea?

El entrenamiento y la inferencia tienen perfiles diferentes. Durante el entrenamiento se ajusta el modelo y se prueban opciones. Durante la inferencia, el modelo ya preparado responde a cada solicitud. En un laboratorio puede pesar más el entrenamiento. En un servicio masivo puede dominar la suma de las inferencias [7]. Por eso, no se debe calcular todo el impacto a partir del entrenamiento inicial ni de una sola consulta.

Los modelos grandes también pueden aumentar la demanda de aceleradores y favorecer la renovación de la infraestructura. Pero el tamaño del modelo no basta para conocer su impacto. Importan el equipo, el programa, el número de consultas, el tiempo de actividad y la proporción de la capacidad que realmente se aprovecha. Una optimización de software puede evitar operaciones; un servidor nuevo puede hacer más trabajo por unidad de energía; y una instalación puede mejorar su enfriamiento. A la vez, fabricar equipos nuevos añade materiales, energía y residuos. Las fuentes revisadas no permiten fijar una frecuencia universal de reemplazo [4, 5].

La escala crea otra tensión. Si una operación se vuelve más eficiente y barata, puede aumentar el número total de usos. El crecimiento de la demanda puede borrar parte del ahorro: es el posible efecto rebote [4]. No es un resultado inevitable, pero obliga a medir dos cosas al mismo tiempo: el costo por operación y el consumo agregado.

4.4. No existe una única huella de la IA

La misma cantidad de electricidad no produce las mismas emisiones en todos los lugares. El resultado depende de las fuentes que alimentan la red y del momento en que se usa la energía. En un estudio sobre la expansión de servidores de IA en Estados Unidos, Xiao y sus colaboradores estiman entre 24 y 44 millones de toneladas adicionales de dióxido de carbono equivalente al año durante el periodo de 2024 a 2030 [4]. La cifra no describe la huella mundial de la IA ni la de un modelo. Resume escenarios para un país y cambia con la cantidad de servidores, su eficiencia, su ubicación y la evolución de la red eléctrica.

El agua varía todavía más. En los escenarios estudiados por Lei y sus colaboradores, el consumo por carga de trabajo cambió más de 10,000 veces [5]. Esta diferencia muestra el peso del servidor, el clima, el enfriamiento y la fuente eléctrica. No debe leerse como una comparación directa de todos los centros de datos del mundo. El modelo del estudio se concentra principalmente en servidores y no incluye de manera completa GPU, almacenamiento y redes.

La ubicación produce intercambios difíciles. Trasladar el cómputo a una red con menos emisiones puede reducir carbono, pero el lugar podría tener poca agua o capacidad limitada para transportar electricidad. Algunos sistemas de enfriamiento ahorran agua y usan más energía; otros hacen lo contrario [4, 5]. Ningún indicador aislado decide cuál es la mejor ubicación.

La falta de datos aumenta la incertidumbre. Los informes empresariales suelen mezclar las cargas de IA con otras actividades del centro de datos. También existe más información sobre la operación que sobre la fabricación de hardware [16]. Un informe útil debería decir qué se midió, dónde, durante cuánto tiempo y con qué equipo. También debería separar, cuando sea posible, entrenamiento, inferencia y otras cargas digitales.

4.5. Respuestas y prácticas internacionales

Los gobiernos ya experimentan con instrumentos que no regulan directamente un modelo, sino la infraestructura que permite operarlo. Es una diferencia importante: una regla para un centro de datos puede afectar servicios de IA, pero también muchas otras actividades digitales.

Singapur muestra una intervención escalonada. En 2019 suspendió la construcción de nuevos centros de datos ante la presión sobre energía, tierra y emisiones. En 2022 levantó la pausa con una cuota menor y nuevos requisitos ambientales. Las nuevas instalaciones deben cumplir criterios de diseño, certificación y una ruta hacia energía renovable. El caso muestra para qué puede servir una moratoria: detener temporalmente el crecimiento para revisar la estrategia. También muestra su límite. Una restricción prolongada puede desplazar inversiones y costos ambientales hacia países vecinos con reglas distintas [17].

Irlanda enfrenta otro problema: una gran concentración de centros de datos dentro de una red eléctrica en transición. La expansión digital se ha cruzado con la salida de combustibles como la turba, la construcción de energías renovables y las decisiones sobre dónde ubicar nuevas instalaciones. Ante el riesgo de saturación en Dublín, el regulador recomendó considerar la ubicación y la capacidad de aportar generación o almacenamiento propios [18]. El dilema no es sólo cuánta electricidad se consume, sino qué usos compiten por la red, dónde se construye nueva capacidad y quién asume la transformación del territorio.

Los Países Bajos y su restricción temporal en Ámsterdam ofrecen una tercera señal. Junto con los casos de Singapur e Irlanda, muestran que la planeación territorial y energética se ha convertido en una herramienta de política digital [17]. Estas medidas pueden ganar tiempo y establecer condiciones de eficiencia, pero no eliminan la demanda. También pueden moverla a otra región. Por eso, no son recetas que puedan copiarse sin considerar clima, red eléctrica, agua, suelo, instituciones y objetivos de desarrollo.

Los tres casos dejan una lección para la infraestructura asociada con IA: la gobernanza empieza antes de encender un modelo. Incluye permisos, localización, capacidad de la red, estándares de eficiencia y datos verificables sobre la operación. También exige distinguir entre reducir un impacto y trasladarlo.

4.6. IA para la sostenibilidad

La relación entre IA y ambiente no es únicamente negativa. Los sistemas de predicción y optimización pueden apoyar la gestión de energía, el monitoreo ambiental o el uso más eficiente de una instalación. Incluso dentro de un centro de datos, el aprendizaje automático puede ayudar a ajustar recursos y enfriamiento [15, 17]. Sin embargo, una aplicación útil no compensa automáticamente el costo de producirla y operarla.

La pregunta correcta es comparativa: ¿qué daño evita o qué recurso ahorra la aplicación, y cuánto requiere para conseguirlo? Esa evaluación necesita un límite común. No sería válido comparar un beneficio acumulado durante años con el costo de una sola operación, ni atribuir a la IA un ahorro producido también por cambios organizativos o de infraestructura.

La reducción requiere actuar en varias capas. El programa puede evitar operaciones innecesarias; el servidor puede aprovechar mejor su capacidad; el centro de datos puede mejorar el enfriamiento; y la red puede incorporar fuentes con menos emisiones. En los escenarios de Xiao y sus colaboradores para Estados Unidos, combinar eficiencia, ubicación y cambios en la red redujo de manera importante emisiones y agua frente a otros escenarios [4]. Esas reducciones no son resultados ya alcanzados ni porcentajes transferibles a cualquier país.

La responsabilidad también debe seguir la capacidad de actuar. Las empresas pueden medir y publicar datos comparables. Los gobiernos pueden fijar reglas sobre información, agua, energía y ubicación. La academia puede declarar el costo computacional de sus investigaciones. Las organizaciones usuarias pueden elegir modelos acordes con la tarea. Los usuarios influyen mediante

la demanda, pero rara vez controlan la infraestructura. Publicar datos no reduce por sí mismo el impacto; permite localizarlo, comprobar si una medida funciona y exigir responsabilidades.

En resumen, la IA generativa añadió nuevas presiones a una infraestructura anterior. Evaluarlas exige distinguir centros de datos, servicios digitales e IA; demanda y eficiencia; entrenamiento e inferencia; operación y ciclo de vida. En vez de preguntar cuánto consume «la IA», conviene preguntar qué servicio se ofrece, con qué modelo y equipo, cuántas veces se usa, dónde se procesa y qué recursos compiten en ese territorio.

5. Conclusiones

La evaluación de la IA no puede quedarse en sus capacidades técnicas. También debe examinar las condiciones de desarrollo y uso, la distribución de beneficios y riesgos, y los costos jurídicos, sociales y ambientales. Esta es la idea que une todo el ensayo. Los efectos no nacen sólo del modelo. También dependen de los datos, la infraestructura, las reglas de la organización y las personas que toman decisiones.

En el terreno legal, la respuesta no consiste en elegir entre innovación y regulación. Consiste en crear controles proporcionales al riesgo. Las experiencias internacionales muestran que esto puede intentarse mediante una norma horizontal, reglas para servicios concretos o autoridades sectoriales. Ninguna arquitectura es neutral ni puede copiarse sin atender el contexto. La privacidad y la no discriminación necesitan documentos, pruebas, formas de cuestionar una decisión y medios para reparar el daño. La transparencia, la explicación, la trazabilidad y la auditoría ayudan de formas distintas, pero ninguna basta por sí sola. La rendición de cuentas exige saber quién debe explicar una decisión, quién puede revisarla y qué sucede si se encuentra un daño [3, 10, 12, 13].

En el terreno ambiental, tampoco existe una respuesta única. La IA generativa no inventó la huella de la infraestructura digital: añadió cargas nuevas a centros de datos que ya consumían electricidad y agua. La energía, el agua y las emisiones cambian con la tarea, el equipo, el lugar y la fuente de electricidad. La fabricación y el reemplazo del hardware agregan impactos que todavía no se conocen con suficiente detalle. La eficiencia es necesaria, pero puede no reducir el consumo total si la demanda crece al mismo tiempo. Medir bien implica distinguir infraestructura digital e IA, declarar límites e incertidumbres y observar a la vez demanda y eficiencia [4, 5, 7, 14, 16].

Los dos problemas se encuentran en un punto común: sin información verificable es difícil gobernar. Los registros permiten seguir decisiones, identificar responsables y evaluar resultados. En el ámbito ambiental cumplen una función parecida cuando muestran energía, agua, emisiones, ubicación y cantidad de trabajo procesado. Por eso, la transparencia ambiental también es una forma de rendición de cuentas [1, 12, 16].

Esta conclusión deja preguntas abiertas para el debate. ¿Qué evidencia debería exigirse antes de usar IA en una decisión de alto impacto? ¿Cómo se reparten las obligaciones entre quienes crean el modelo, ofrecen la infraestructura y lo aplican? ¿Qué necesita saber una persona para cuestionar una decisión? ¿Qué medidas permiten comparar el impacto ambiental de servicios operados en lugares

distintos? ¿Cómo podemos saber si una mejora de eficiencia reduce el consumo total y no sólo el costo de cada operación?

Estas preguntas son más útiles que decidir si la IA es buena o mala en general. Obligan a examinar cada uso, sus objetivos y sus consecuencias. Una posición informada puede reconocer beneficios sin ocultar los costos que recaen en personas, instituciones y territorios. También puede pedir reglas y reducciones de impacto sin suponer que una sola ley, auditoría o mejora técnica resolverá todo. El criterio final debería ser sencillo: saber para qué se usa cada sistema, qué recursos necesita, quién obtiene sus beneficios, quién asume sus costos y con qué evidencia podremos revisar esas decisiones.

Referencias

[1] A. Batool, D. Zowghi y M. Bano, «AI governance: A systematic literature review», *AI and Ethics*, vol. 5, pp. 3265–3279, 2025, doi: 10.1007/s43681-024-00653-w.

[2] M. A. Medina Romero y T. H. Torres Chávez, «Regulación de la Inteligencia Artificial: Desafíos para los Derechos Humanos en México», *RIDE. Revista Iberoamericana para la Investigación y el Desarrollo Educativo*, vol. 15, núm. 30, art. e833, 2025, doi: 10.23913/ride.v15i30.2291.

[3] J. L. Ordelin Font, «Cargas normativas, innovación e inteligencia artificial: dilemas regulatorios», *Estudios en Derecho a la Información*, vol. 10, núm. 20, pp. 81–100, 2025, doi: 10.22201/iij.25940082e.2025.20.19491.

[4] T. Xiao, F. Fuso Nerini, H. D. Matthews, M. Tavoni y F. You, «Environmental impact and net-zero pathways for sustainable artificial intelligence servers in the USA», *Nature Sustainability*, vol. 8, pp. 1541–1553, 2025, doi: 10.1038/s41893-025-01681-y.

[5] N. Lei, J. Lu, A. Shehabi y E. Masanet, «The water use of data center workloads: A review and assessment of key determinants», *Resources, Conservation and Recycling*, vol. 219, art. 108310, 2025, doi: 10.1016/j.resconrec.2025.108310.

[6] E. M. Bender, T. Gebru, A. McMillan-Major y S. Shmitchell, «On the dangers of stochastic parrots: Can language models be too big?», en *Proc. 2021 ACM Conf. Fairness, Accountability, and Transparency (FAccT '21)*, 2021, pp. 610–623, doi: 10.1145/3442188.3445922.

[7] R. Schwartz, J. Dodge, N. A. Smith y O. Etzioni, «Green AI», *Communications of the ACM*, vol. 63, núm. 12, pp. 54–63, 2020, doi: 10.1145/3381831.

[8] S. Buijsman, «Transparency for AI systems: A value-based approach», *Ethics and Information Technology*, vol. 26, art. 34, 2024, doi: 10.1007/s10676-024-09770-w.

[9] M. Veale y F. Zuiderveen Borgesius, «Demystifying the Draft EU Artificial Intelligence Act: Analysing the good, the bad, and the unclear elements of the proposed approach», *Computer Law Review International*, vol. 22, núm. 4, pp. 97–112, 2021, doi: 10.9785/cri-2021-220402.

[10] C. Poncibò y M. Ebers, «Comparative perspectives on the regulation of large language models», *Cambridge Forum on AI: Law and Governance*, vol. 1, art. e10, pp. 1–5, 2025, doi: 10.1017/cfl.2024.14.

[11] P. Zhang, K. Jayakar, R. Taylor y C. Liu, «Same goal, different paths: Contrasting approaches to AI regulation in China and India», *Telecommunications Policy*, vol. 49, art. 103019, 2025, doi: 10.1016/j.telpol.2025.103019.

[12] J. Mökander, «Auditing of AI: Legal, ethical and technical approaches», *Digital Society*, vol. 2, art. 49, 2023, doi: 10.1007/s44206-023-00074-y.

[13] C. Novelli, M. Taddeo y L. Floridi, «Accountability in artificial intelligence: What it is and how it works», *AI & Society*, vol. 39, pp. 1871–1882, 2024, doi: 10.1007/s00146-023-01635-y.

[14] E. Masanet, A. Shehabi, N. Lei, S. Smith y J. Koomey, «Recalibrating global data center energy-use estimates», *Science*, vol. 367, núm. 6481, pp. 984–986, 2020, doi: 10.1126/science.aba3758.

[15] D. Mytton, «Data centre water consumption», *npj Clean Water*, vol. 4, art. 11, 2021, doi: 10.1038/s41545-021-00101-w.

[16] A. de Vries-Gao, «The carbon and water footprints of data centers and what this could mean for artificial intelligence», *Patterns*, vol. 7, art. 101430, 2026, doi: 10.1016/j.patter.2025.101430.

[17] F. H. M. Liu, K. P. Y. Lai, B. Seah y W. T. L. Chow, «Decarbonising digital infrastructure and urban sustainability in the case of data centres», *npj Urban Sustainability*, vol. 5, art. 15, 2025, doi: 10.1038/s42949-025-00203-1.

[18] P. Bresnihan y P. Brodie, «Data sinks, carbon services: Waste, storage and energy cultures on Ireland's peat bogs», *New Media & Society*, vol. 25, núm. 2, pp. 361–383, 2023, doi: 10.1177/14614448221149948.