



SAJA: Situated Algorithmic Justice Assessment

Evaluación comunitaria y contextual de sistemas de IA

Manuel Soto-Romero, Karla Ramírez-Pulido, Ana Cristina Cervantes-Arrioja y Araceli Liliana Reyes-Cabello

UACM / UNAM

Motivación: el problema no es solo técnico

1

IA como mediadora

Empleo, salud, crédito, educación y servicios públicos pasan por decisiones automatizadas.

2

Desigualdad estructural

Los datos, objetivos e instituciones pueden reproducir exclusión histórica.

3

Métrica insuficiente

Un indicador genérico puede ocultar daños que solo aparecen en contexto.

Pregunta guía

¿Cómo evaluar si un sistema de IA reproduce una desigualdad concreta, y no solo si falla una métrica estándar?

Brecha metodológica: la trampa de abstracción

Auditoría estándar

- Parte de atributos sensibles predefinidos.
- Aplica paridad demográfica, igualdad de oportunidad o tasas de error.
- Entrega rigor estadístico, pero puede desconectarse del fenómeno social.

Evaluación situada

- Parte de un problema estructural documentado.
- Incorpora evidencia de comunidades afectadas.
- Justifica que variables, benchmarks y métricas sí corresponden al daño.

La métrica no desaparece: se subordina a una justificación contextual.

Propuesta: SAJA como metodología socio-técnica

SAJA construye indicadores de justicia algorítmica desde el contexto: problema estructural, conocimiento situado, benchmark y medición técnica.

1

Problema estructural

¿Qué desigualdad podría replicar el sistema?

2

Evidencia comunitaria

¿Cómo se experimenta el daño por los grupos afectados?

3

Benchmark situado

¿Qué escenarios controlados capturan esas dimensiones?

4


Métrica contextual

¿Qué indicador corresponde al daño y con qué límites?

Contribución: una cadena auditable que explica por qué cada métrica es relevante.

Mapa de notación: una sola cadena

Se lee de izquierda a derecha: problema -> evidencia -> dimensión -> benchmark -> métrica.



Dentro de cada dimensión d_i se llena una ficha T_i

$$T_i = (e_i, v_i, B_i, m_i, l_i)$$



Artefactos auditables: dónde se documenta la cadena

Notación	Artefacto mínimo	Qué documenta
P -> H	Revisión documental + hipótesis	Desigualdad inicial y mecanismo plausible de replicación.
Q -> e_i	Corpus situado + codebook	Evidencia que sostiene cada dimensión evaluada.
d_i -> v_i	Matriz dimensión-variable	Cómo un daño se convierte en proxy observable.
B_i	Benchmark situado	Contexto fijo y marcador que cambia en casos controlados.
m_i -> l_i	Tarjeta de métrica + reporte	Indicador usado, alcance y límites del proxy.

Métricas contextualizadas: notación de trazabilidad

T_i : ficha de una dimensión d_i

$$T_i = (e_i, v_i, B_i, m_i, l_i)$$

Reúne los elementos definidos en la cadena: evidencia, proxy, benchmark, métrica y límites.

En términos simples: por qué m_i tiene sentido para evaluar d_i .

Δ_i : contraste dentro de B_i

$$\Delta_i = |m_i(S, B_i^a) - m_i(S, B_i^b)|$$

Compara dos versiones del mismo benchmark: B_i^a y B_i^b . Son equivalentes salvo por v_i .

Ejemplo: mismo perfil profesional, cambia el marcador de género.

Idea central: las fórmulas documentan decisiones de medición; no sustituyen la discusión contextual de justicia.

Ilustración: de dimensiones al prompt pareado

Hipótesis: un modelo entrenado con datos históricos puede reproducir asociaciones de género en contextos profesionales y de liderazgo.

1. Las tarjetas son d_i : dimensiones evaluables que indican qué patrón buscar.

d_i : Representación

Qué ocupaciones aparecen.

d_i : Rasgos

Qué rasgos se asignan.

d_i : Agencia

Quién decide y actúa.

d_i : Visibilidad

Quién aparece u omite.



2. Para construir B_i : elegir d_i + fijar contexto + definir v_i + observar con m_i

d_i elegida

rasgos + agencia

v_i proxy

nombre -> género percibido

B_i

prompt pareado

m_i

comparar rasgos y agencia

B_i : prompt pareado derivado de d_i y v_i

"Escribe una biografía profesional breve de María/Alejandro, ingeniera(o) senior que lidera un proyecto complejo."

Alcance, limitaciones y despliegue

Aporta

- Validez contextual para seleccionar métricas.
- Trazabilidad entre daño social y medición técnica.
- Compatibilidad con auditorías, gestión de riesgo y monitoreo.

Cuida

- Representatividad y consentimiento en datos comunitarios.
- Debates al traducir daño social a variables computacionales.
- Menor comparabilidad entre estudios por priorizar contexto.

SAJA-lite: revisión documental breve + consulta acotada + benchmark pequeño + reporte de riesgos medidos y no medidos.

Cierre: justicia algorítmica como relación situada

La pregunta no es solo si un modelo es imparcial en abstracto, sino qué relación produce entre su comportamiento y las condiciones de despliegue.

- 1 SAJA no reemplaza las métricas de fairness: las contextualiza.
- 2 La evidencia comunitaria entra antes de definir qué medir.
- 3 Un buen reporte también documenta límites y dimensiones no medibles.

Preguntas